

# Relatório Técnico: Síntese de Corpus Semântico-Vetorial Orientado a Processamento de Linguagem Natural

## 1. Título e objetivo da base:

- **Título:** AG News Embeddings: Construção de um Espaço Vetorial Denso para Modelagem Preditiva e Agrupamento Semântico.
- **Objetivo:** O presente artefato visa mapear um corpus textual não estruturado em um espaço latente contínuo de alta dimensionalidade via representações vetoriais densas (*embeddings*). A síntese deste conjunto de dados provê o substrato empírico necessário para a condução de tarefas de *downstream* (e.g., *clustering* não supervisionado e classificação linear multiclasse), minimizando o esforço computacional subjacente à extração direta de features morfológicas e sintáticas em tempo de inferência.

## 2. Tipo de dado utilizado:

- Utilizaram-se dados não estruturados de natureza textual, originários de um corpus de narrativas jornalísticas redigidas em língua inglesa, os quais evidenciam alta variância dimensional em vocabulário e contexto semântico.

## 3. Problema ou tema investigado:

- A investigação concentra-se na avaliação da separabilidade topológica em domínios textuais curtos. Fundamentalmente, afere-se a capacidade de arquiteturas baseadas em mecanismos de atenção (Transformers) em reter a semântica de tópicos díspares (finanças corporativas versus crônicas esportivas) sem a necessidade de sintonia fina (*fine-tuning*). A extração *zero-shot* postula que as representações latentes do modelo pré-treinado são suficientes para o isolamento linear das classes no hiperespaço, viabilizando treinamento linear em abordagens subsequentes.

## 4. Origem dos dados e link:

- **Fonte original:** AG News Classification Dataset, benchmark estabelecido na literatura de Processamento de Linguagem Natural (PLN) para avaliação de algoritmos de classificação de textos curtos.
- **Integração:** Instanciação dinâmica via interface programática do repositório *Hugging Face Hub*.
- **URI de Acesso:** [https://huggingface.co/datasets/fancyzhx/ag\\_news](https://huggingface.co/datasets/fancyzhx/ag_news)
- **Licenciamento:** Restrito ao escopo acadêmico e à pesquisa fundamental (Academic / Non-commercial use).

## 5. Quantidade de amostras:

- O dataset estruturado consolida exatamente 1.000 instâncias independentes. Este dimensionamento paramétrico foi projetado para assegurar representatividade estatística nas tarefas preditivas subsequentes, viabilizando a convergência matemática de hiperplanos de separação linear ao mesmo tempo em que restringe a carga computacional alocada.

## 6. Existência ou não de rótulos:

- O conjunto gerado é estritamente supervisionado, dispondo de anotações probabilísticas determinísticas (*ground-truth label*), o que legitima a sua submissão à validação por modelos discriminativos multinomiais.

**7. Descrição das classes:** A estrutura conceitual adota particionamento mutuamente exclusivo, submetido a um processo de subamostragem estratificada que preservou a distribuição empírica perfeitamente balanceada ( $n = 250$  observações equiprováveis por estrato categórico):

- **World (0):** Tópicos subjacentes à diplomacia, conflitos sistêmicos e eventos geopolíticos macrorregionais.
- **Sports (1):** Registros estatísticos e fenomenologia associada a modalidades desportivas globais.
- **Business (2):** Fenômenos macroeconômicos, dinâmicas de mercado, inovações e balanços corporativos corporativos.
- **Sci/Tech (3):** Escopo relativo a marcos de engenharia, Pesquisa & Desenvolvimento e descobertas científicas.

## 8. Modelo utilizado para gerar os embeddings:

- Empregou-se o modelo `sentence-transformers/all-MiniLM-L6-v2`. Trata-se de uma arquitetura base otimizada via destilação de conhecimento (*knowledge distillation*), visando rigorosa eficiência computacional (redução de tensores paramétricos) sem perda de expressividade semântica em relação ao *teacher model* originário.

## 9. Dimensão dos embeddings produzidos:

- A rede projeta a sequência de tokens convolucionada em um vetor ortogonal de dimensionalidade  $\mathbb{R}^{384}$ . A adoção do produto interno (similaridade do cosseno) no espaço  $\mathbb{R}^{384}$  como métrica de distância natural justifica-se teoricamente, dado que a operação mensura o alinhamento angular estrito entre vetores normalizados pela norma- $L_2$ . Tal normalização neutraliza as distorções oriundas da magnitude absoluta do documento fonte (comprimento da sentença), priorizando estritamente o grau de interseção e a proximidade semântica para os processos de agrupamento iterativo que sucedem a extração.

**10. Etapas de coleta, seleção e processamento:** O pipeline algorítmico de transformação de dados e projeção vetorial obedeceu à seguinte formalização metodológica:

1. **Ingestão Base:** Requisição assíncrona via *Application Programming Interface* (API) para a materialização do conjunto de dados *AG News* no ambiente de memória volátil.
2. **Subamostragem Estratificada:** Execução de uma heurística de particionamento pseudoaleatório restrito por estrato (governado por uma semente criptográfica invariante). A etapa mitigou o desequilíbrio estrutural, evitando a introdução de vieses no limite de decisão da topologia classificada.
3. **Mapeamento Latente:** O corpus textual estruturado foi convertido em tensores estendidos e alocados para inferência *batch* em hardware otimizado (GPU). O codificador realizou o mapeamento não-linear unívoco das cadeias de caracteres discretas para o subespaço denso de representações ortogonais, garantindo a agregação de semânticas composicionais por meio de *mean pooling*.
4. **Agregação de Metadados Invariantes:** Acoplamento determinístico do cômputo de frequência espacial de *features* brutas (cardinalidade isolada de vocábulos e

comprimento de *string*), complementado por rastreabilidade de licenciamento, o que instrumentaliza análises de correlação cruzada em etapas subsequentes de EDA.

5. **Persistência e Estruturação Tabular:** Consolidação integral da matriz esparsa. O vetor identificador primário (ID), a matriz contínua subjacente (384 *features* independentes), o vetor alvo e o vetor de metadados categóricos compuseram o *dataframe* final, sendo serializados para o artefato persistente `agnews_embeddings_1000.csv` (codificação UTF-8).

**11. Validação Empírica e Resultados Preliminares (*Downstream Tasks*):** A validação do artefato estruturado foi conduzida mediante submissão a *pipelines* de modelagem analítica, atestando a qualidade intrínseca do subespaço vetorial:

- **Projeção Topológica (PCA):** A redução de dimensionalidade linear de  $\mathbb{R}^{384}$  para  $\mathbb{R}^2$  via decomposição de autovalores (Análise de Componentes Principais) revelou a emergência de *clusters* semânticos naturais. ! [Projeção PCA 2D](c:/Pos graduação/Doutorado/Ciencia de Dados/Trabalho/pca\_clusters.png)
- **Modelagem Discriminativa (*Baseline Linear*):** O ajuste de um hiperplano de Regressão Logística Multinomial (com regularização penalizada  $L_2$ ) obteve acurácia convergente de **78.3%** (*F1-Score macro* de 0.78). A classe *Sports* apresentou *precision* global máxima (0.93), indicando elevada ortogonalidade e isolamento topológico em relação aos demais tópicos econômico-científicos. Tal performance — obtida puramente via representações *zero-shot* — evidencia a maturidade descritiva dos tensores sem *fine-tuning*. ! [Matriz de Confusão](c:/Pos graduação/Doutorado/Ciencia de Dados/Trabalho/confusion\_matrix.png)
- **Resiliência Estocástica (*Label Noise*):** Sob a perturbação randômica de 10% da variável alvo no subconjunto de treinamento, o modelo regressor demonstrou baixa degradação entrópica, retraindo a métrica generalista em estritos 7.5 pontos percentuais, confirmando a robustez estrutural das representações contínuas contra anomalias (*outliers* espaciais).

**12. Link compartilhado do Colab executado:**

- <https://colab.research.google.com/drive/1zpIsI3IHhf-XPCJuaS07DrpnqbWIU5I1?usp=sharing>